ACA N.° 2 — Aprendizaje Automático aplicado a Ventas

CUN · Especialización en Inteligencia Artificial · Docente: Hamilton Rivera Flor

Integrantes

Integrantes: completar antes de entregar

Objetivo general

Desarrollar, entrenar y desplegar redes neuronales profundas (CNN, RNN secuencial y Transformer) que pronostiquen las ventas diarias de una tienda minorista, integrando preprocesamiento, entrenamiento, evaluacion comparativa y una interfaz interactiva en Streamlit.

Pregunta orientadora / Problema

¿En qué medida distintas arquitecturas de redes neuronales (convolucional, recurrente y basada en atención) logran aprender patrones temporales en transacciones comerciales para anticipar las ventas del día siguiente, y cuál ofrece mejor desempeño?

Dataset

Sales Forecasting - Retail Superstore (train.csv): 9.800 transacciones, periodo 2015-2018, agregadas a serie diaria de ventas (variable 'Sales', en USD). Gestionado en 3 bases SQLite: transacciones, analítica y predicciones.

Flujo metodológico

1) EDA + gestión SQL → 2) Ventanas deslizantes de 28 días + aumento de datos (ruido gaussiano) → 3) Entrenamiento de CNN, RNN (LSTM+GRU) y Transformer → 4) Métricas comparativas (MAE, RMSE, sMAPE, R2, F1) → 5) Despliegue en Streamlit.

Arquitecturas comparadas

CNN (Conv1D): 2 bloques convolucionales + pooling global; capta patrones locales de corto plazo en la ventana temporal.
Secuencial (LSTM + GRU): capa LSTM seguida de GRU; modela dependencias temporales de mediano/largo plazo con memoria.
Transformer: proyección + codificación posicional + auto-atención multi-cabeza (2 capas); pondera dinámicamente la importancia de cada día de la ventana.

Resultados principales (partición de prueba)

Modelo	MAE	RMSE	sMAPE%	R2	F1 alta venta
CNN (Conv1D)	1802	2730	92.0	-0.12	0.00
Secuencial (LSTM+GRU)	1808	2693	91.7	-0.09	0.30
Transformer (atencion)	1806	2698	90.9	-0.10	0.00

Vista previa de la aplicación

La app Streamlit permite: explorar los datos (EDA), consultar las bases SQL, seleccionar la arquitectura (CNN / Secuencial / Transformer), visualizar curvas de entrenamiento y matriz de confusión, y generar el pronóstico del día siguiente de forma interactiva.

Conclusiones

Las tres arquitecturas superan ligeramente la base ingenua semanal en términos de MAE, aunque el R2 negativo/cercano a cero evidencia que la serie, al carecer de variables exógenas (clima, promociones, inventario), limita la capacidad predictiva de cualquier red; no debe emplearse como sistema comercial sin ampliar las variables de entrada.

URL pública: se genera en la celda de ngrok de abajo

URL del video: pendiente de grabacion